

시험 점수 예측 분석 프레젠테이션

통계 분석 및 머신러닝

프로젝트 기간 26.01.17 ~ 26.01.29



CONTENTS

01. 분석 개요 _____ 03

02. 데이터 및 변수 _____ 07

03. 통계 분석 결과 _____ 09

04. 머신러닝 분석 결과 _____ 16

05. 결론 _____ 00



01

분석 개요

성적 중심의 사회

2020 ~ 2025년 취학률 현황

	2020	2021	2022	2023	2024	2025
초등학교	98.2	98.1	98.5	99.7	100.2	99.9
중학교	95.1	97.3	98.1	96.8	95.8	97.3
고등학교	90.5	95.3	94.5	93	93.9	94.4
대학교	71	72	71.5	74.9	74.9	76.3

출처 : 한국교육개발원 교육통계분석자료집



분석 목적

학생들의 학업 성적은 단순한 점수가 아니다
개개인 마다 같은 점수라도 원인이 다르다



높은 대학 진학률

2025년 기준 76.3%의 높은 대학 진학률



수많은 재화의 투입


사교육 참여율 80% / 총액 29.2 조원



18년 연속 진학률 1위


OECD 평균 48.4%를 훌쩍 넘으며
18년 연속 대학 진학률 1위 기록

심화되는 경쟁과 악순환



N수생 증가세

최근 5년 이상 N수생 비율이 30%를 넘나들며 증가하는 추세
교육부 분석에서도 졸업생 응시 비율은 30%대를 크게 상회함



사교육 과열

만 5세 영유아 아이들 사교육 참여율 80%
사교육비 총액은 작년도 대비 7.7% 증가한 29조 2000억원

핵심 목표 및 질문



그렇다면 무엇이 성적에 가장 큰 영향을 줄까?



어떤 변수가 학생의 성적과 가장 강하게 연결되는가?



그 영향이 단순히 유의한 것을 넘어 어느 수준으로 의미가 있는가?



성적과 가장 강하게 연결되는 변수를 움직이는 요인은 무엇인가?



02

데이터 및 변수

데이터 및 변수 상세 설명

ID	Age	Gender	Course	Study_hours	Class_attendance	internet_access
0	21	female	b.sc	7.91	98.8	no
1	18	other	diploma	4.95	94.8	yes
2	20	female	b.sc	4.68	92.6	yes
...	...	...	...	...	...	...
629997	24	male	bca	0.64	44.2	yes
629998	20	male	b.com	1.54	75.1	yes
629999	18	other	b.tech	3.94	75.3	yes

데이터 수

13개의 컬럼을 가진 63만개의 데이터



변수 타입

7개의 범주형 변수와 5개의 수치형 변수



타겟 변수

exam_score가 포함된 데이터



결측치

모든 변수에서 결측치 관측 X





03

통계 분석 결과

학업 성적에 미치는 효과 크기

[수치형]

feature	type	metric	effect_size	p_value
study_hours	numeric	spearman_rho	0.7697	0.0000
class_attendance	numeric	spearman_rho	0.3515	0.0000
sleep_hours	numeric	spearman_rho	0.1600	0.0000
age	numeric	spearman_rho	0.0071	0.0000

[범주형]

feature	type	metric	effect_size	p_value
sleep_quality	categorical	eta_squared(ANOVA)	0.0561	0.0000
study_method	categorical	eta_squared(ANOVA)	0.0501	0.0000
facility_rating	categorical	eta_squared(ANOVA)	0.0357	0.0000
course	categorical	eta_squared(ANOVA)	0.0003	0.0000
gender	categorical	eta_squared(ANOVA)	0.0001	0.0000
exam_difficulty	categorical	eta_squared(ANOVA)	0.0001	0.0000

수치형 변수

Spearman 순위상관 계수
값 자체 대신 값의 크기를 기준으로 순서를 정해 증감 경향
0.10 ≤ | ρ | < 0.30 : 작음
0.30 ≤ | ρ | < 0.50 : 중간
0.50 ≤ | ρ | < 0.70 : 큼 →

범주형 변수

η²(eta-squared)
η² ~ 0.01 : 작은 효과
η² ~ 0.06 : 중간 효과
η² ~ 0.14 : 큰 효과 →

대부분 유의한 영향

통제변수를 제외한 7개의 변수 중 6개가 유의한 효과 미침

학업 성적에 미치는 효과 크기

층화 샘플링 t-test

mean(yes)	mean(no)	mean_diff	p	Cohen's d
63.489	62.125	1.364	0.8097	0.0686

No그룹의 수가 현저히 적어 샘플링시 불균형 샘플링이 됨



균형 샘플링 t-test

mean(yes)	mean(no)	mean_diff	p	Cohen's d
60.954	63.744	-2.790	0.4604	-0.1482

p-value가 매우 높아 유의하지 않음



반복 샘플링 (200회)

유의(p < 0.05) 확률	mean_diff 평균	Cohen's d 평균
6.50%	-0.445	-0.023

유의 확률이 매우 낮고 효과 크기도 작음



학습 시간 위계적 다중선행회귀

	Model1 (나이, 성별, 전공)	Model2 (시험 난이도)	Model3 (출석률, 수면)	Model 4 (학습 방법 , 환경)
R ²	0.00034	0.00052	0.01232	0.01663

0.00034

[설명력 : 0.03%]

Model 1

나이, 성별, 전공으로 설명되는 학습 시간
설명력이 매우 낮음

0.00052

[Model 1 + 0.00018]
[설명력 : 0.05%]

Model 2

Model 1 대비 0.018%p 상승
난이도의 설명력이 매우 낮음

0.01232

[Model 2 + 0.01179]
[설명력 : 1.23%]

Model 3

설명력이 가장 많이 증가한 부분
하지만 그래도 설명력이 낮음

0.01663

[Model 3 + 0.00431]
[설명력 : 1.66%]

Model 4

학습 방법 / 환경 변수도 설명력이 크지 않음

출석률 표준화 OLS 계수

[수치형 변수의 표준편차]


	class_attendance(종속변수)	study_hours	sleep_hours
STD	17.4285	2.3596	1.7472

feature	type	비교 / 단위	표준화 계수 (β_std)	출석률 변화(%p)
study_hours	numeric	+1 SD	0.0815	1.421
facility_rating	categorical	low vs high(기준)	-0.0705	-1.230
internet_access	categorical	yes vs no(기준)	0.0480	0.837
study_method	categorical	self-study vs coaching(기준)	-0.0352	-0.613
facility_rating	categorical	medium vs high(기준)	-0.0325	-0.566
sleep_hours	numeric	+1 SD	0.0247	0.430
study_method	categorical	group study vs coaching(기준)	0.0212	0.370
study_method	categorical	mixed vs coaching(기준)	0.0168	0.292
sleep_quality	categorical	good vs average(기준)	-0.0094	-0.164
sleep_quality	categorical	poor vs average(기준)	0.0081	0.142
exam_difficulty	categorical	hard vs easy(기준)	-0.0048	-0.083
exam_difficulty	categorical	moderate vs easy(기준)	0.0017	0.029
study_method	categorical	online videos vs coaching(기준)	-0.0001	-0.003

EX) 학습시간이 1표준편차 (2.36시간)만큼 증가하면 출석률은 출석률 표준편차 * 학습시간 표준화 계수(17.4285 * 0.0815 = 1.421%p)만큼 증가한다

출석률 표준화 OLS 계수 시각화 및 요약

출석률 변화(%p) 시각화



변화 $\geq 1.0\%$: 효과 있음
1.0 > 변화 $\geq 0.5\%$: 꽤 효과 있음
0.5 > 변화 $\geq 0.2\%$: 작은 효과 있음
0.2 > 변화 : 효과 없음

출석률 상승 요인 TOP 5

출석률 상승 요인	변화(%p)
study_hours (+1 SD)	1.421
internet_access (yes vs no(기준))	0.837
sleep_hours (+1 SD)	0.430
study_method (group study vs coaching(기준))	0.370
study_method (mixed vs coaching(기준))	0.292

모두 0.2%p 이상으로 출석률 상승에 효과를 줌

출석률 하락 요인 TOP 5

출석률 하락 요인	변화(%p)
facility_rating (low vs high(기준))	-1.230
study_method (self-study vs coaching(기준))	-0.837
facility_rating (medium vs high(기준))	-0.430
sleep_quality (good vs average(기준))	-0.370
exam_difficulty (hard vs easy(기준))	-0.292

모두 0.2%p 이상으로 출석률 하락에 효과를 줌

수면의 질 순서형로지스틱회귀

긍정적 영향 오즈비 TOP 5

feature	coef	오즈비	오즈 변화
시설 만족도 = 보통 (vs 높음)	0.0680	1.0704	7.04%
인터넷 접근 = Yes (vs No)	0.0533	1.0548	5.48%
학습 시간	0.0388	1.0396	3.96%
시험 난이도 = 평범 (vs 쉬움)	0.0370	1.0377	3.77%
수면 시간	0.0258	1.0262	1.64%

부정적 영향 오즈비 TOP 5


feature	coef	오즈비	오즈 변화
학습 방법 = 자습 (vs 코칭)	-0.1037	0.9015	-9.85%
학습 방법 = 혼합 (vs 코칭)	-0.0690	0.9932	-6.68%
학습 방법 = 온라인 비디오 (vs 코칭)	-0.0460	0.9550	-4.50%
시설 만족도 = 낮음 (vs 높음)	-0.0085	0.9915	-0.85%
출석률	-0.0004	0.9995	-0.05%



04

머신러닝 분석 결과

데이터 분할



80% 학습 데이터


20% 검증 데이터

전체 데이터를 학습 및 검증 데이터로 분할

과적합 방지를 위해 분리

데이터 분할 시 재현성 보장

파이프라인 설계



모델 적합 및 RMSE

Baseline Model

Ridge RMSE : 8.89482
Ridge std : 0.01008

HGBR RMSE : 8.82526
HGBR std : 0.01497

XGB RMSE : 8.80710
XGB std : 0.01261




New Model

Ridge RMSE : 8.89482
Ridge std : 0.01008

HGBR RMSE : 8.77588
HGBR std : 0.00938

XGB RMSE : 8.77910
XGB std : 0.01245

SHAP 분석



학습 시간

높은 값인 붉은색이 양수 범위인 우측에 분포
낮은 값인 푸른색은 음수 범위인 좌측에 분포




출석률

학습 시간과 비슷한 형태, 좌우 범위가 짧음



수면의 질


수면의 질이 poor인 경우, 음수에 위치
수면의 질이 good인 경우, 양수에 위치



영향이 작은 요인

age, gender, course 등은 거의 0에 수렴

OOF 예측 및 RMSE



OOF(Out-Of-Fold)


K-fold 교차검증 과정에서 각 샘플이 학습에 포함되지 않은 상태에서 생성된 예측값 전체 학습 데이터를 K개 폴드로 나누고 매 반복에서 1개 폴드를 검증 데이터로 사용 나머지 K-1개 폴드로 모델 학습 후, 검증 폴드에 대해서 예측 수행



최적의 가중치 조합

$\text{Ridge} * 0.00 + \text{HGBR} * 0.55 + \text{XGB} * 0.45 \Rightarrow \text{RMSE} : 8.76852$

RMSE 및 Kaggle Public Score 개선 결과



+0.44%

RMSE 0.44% 개선

Baseline Model RMSE : 8.80710 → New Model RMSE : 8.76852

+0.53%

Kaggle Public Score 0.53% 개선

Kaggle Public Score : 8.78096 → 8.73424 로 0.53% 개선됨

통계·머신러닝 통합 인사이드

학업 성적에 영향을 미치는 요인

- ✓ 학습 시간
- ✓ 출석률
- ✓ 수면의 질
- ✓ 학습 방법



출석률에 영향을 미치는 요인

- + 학습 시간
- + 인터넷 접근성 (Yes)
- + 수면 시간
- 시설 만족도 (낮음)
- 학습 방법 (자습)
- 시설 만족도 (보통)



수면의 질에 영향을 미치는 요인

- + 시설 만족도 (보통)
- + 학습 시간
- + 수면 시간
- 학습 방법 (자습)
- 학습 방법 (혼합)
- 학습 방법 (온라인 비디오)



THANK YOU

감사합니다.

Kaggle Playground 시험 점수 예측 분석

